Mirror Descent 入门

Basiliscus

2026 年 9 月 23 日

阅读主线：梯度下降的最小化形式 → 用 Bregman 散度替换平方距离 → 镜像坐标更新 → 负熵例子 → 与近端梯度、连续流的联系。沿用原稿：f 为目标函数，ϕ 为镜像函数，$\eta > 0$ 为 Mirror Descent 步长；复合问题仍写为 $\psi = f + h$，近端梯度步长仍用 t_k。这里的 h 是函数，不是时间步长。

1 从普通梯度下降出发

考虑 $\min_x f(x)$。普通梯度下降是

$$x_{k+1} = x_k - \eta \nabla f(x_k). \tag{1}$$

它等价于最小化一个局部模型：

$$x_{k+1} = \arg\min_x \left\{ \langle \nabla f(x_k), x - x_k \rangle + \frac{1}{2\eta} \|x - x_k\|_2^2 \right\}. \tag{2}$$

第一项是目标函数的一阶变化；第二项限制这一步不要走得过远。求一阶条件：

$$0 = \nabla f(x_k) + \frac{1}{\eta}(x_{k+1} - x_k),$$

即回到式 (**??**)。常数项 $f(x_k)$ 对极小点无影响，所以可以加上，也可以省略。

Mirror Descent 的出发点：能否换一种更适合变量结构的方式衡量「离 x_k 多远」？它仍然可以在 $\mathbb{R}^n$ 中进行；改变的是几何及更新方式，并非一定换到另一个空间。

2 Bregman 散度与 Mirror Descent 更新

2.1 由镜像函数定义散度

选取凸函数 ϕ，在第二个变量 y 处可微，定义

$$\boxed{D_\phi(x, y) = \phi(x) - \phi(y) - \langle \nabla \phi(y), x - y \rangle.} \tag{3}$$

它衡量 $\phi(x)$ 与 ϕ 在 y 处的一阶近似之间的差。凸性给出

$$\phi(x) \geq \phi(y) + \langle \nabla \phi(y), x - y \rangle, \qquad D_\phi(x, y) \geq 0.$$

严格凸性保证在适用的定义域内 $x \neq y$ 时 $D_\phi(x,y) > 0$。算法中通常还需要更强的性质，以保证子问题有唯一解、镜像映射可逆等；不是任意凸函数都适合直接拿来用。

不要把它当成普通距离：一般 $D_\phi(x,y) \neq D_\phi(y,x)$，也不满足三角不等式。下面始终在第一个变量上最小化，使用的是 $D_\phi(x,x_k)$，不能随意交换两个位置。

2.2 把平方距离替换掉

对闭凸可行集 X，Mirror Descent 的基本形式为

$$\boxed{x_{k+1} = \arg\min_{x\in X} \left\{ \langle \nabla f(x_k), x - x_k\rangle + \frac{1}{\eta} D_\phi(x, x_k) \right\}.} \tag{4}$$

其中 x_k 位于 ϕ 可微的区域，并假设该子问题有解。展开散度后，

$$x_{k+1} = \arg\min_{x\in X} \Big\{ \langle \nabla f(x_k), x - x_k\rangle + \frac{1}{\eta}\big[\phi(x) - \phi(x_k) - \langle \nabla\phi(x_k), x - x_k\rangle\big] \Big\}.$$

与梯度下降一样，目标函数被线性化；不同之处是控制步长的项换成了 D_ϕ。

2.3 欧氏情形：恢复梯度下降

取 $\phi(x) = \frac{1}{2}\|x\|_2^2$，则 $\nabla\phi(y) = y$，且

$$\begin{aligned} D_\phi(x,y) &= \frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|y\|_2^2 - \langle y, x - y\rangle \\ &= \frac{1}{2}\|x - y\|_2^2. \end{aligned}$$

所以式 (**??**) 回到式 (**??**)。无约束时是普通梯度下降；若有约束 $x \in X$，则是投影梯度下降

$$x_{k+1} = \Pi_X\big(x_k - \eta\nabla f(x_k)\big).$$

3 「Mirror」的关键：在镜像坐标里做加法

先看没有活跃约束、极小点位于可微区域内部的情形。因为

$$\nabla_x D_\phi(x, x_k) = \nabla\phi(x) - \nabla\phi(x_k),$$

式 (**??**) 的一阶条件为

$$0 = \nabla f(x_k) + \frac{1}{\eta}\big[\nabla\phi(x_{k+1}) - \nabla\phi(x_k)\big].$$

于是

$$\boxed{\nabla\phi(x_{k+1}) = \nabla\phi(x_k) - \eta\nabla f(x_k).} \tag{5}$$

若定义 $z_k = \nabla\phi(x_k)$，并且右端仍位于 $\nabla\phi$ 的可逆值域内，就得到

$$\boxed{z_k = \nabla\phi(x_k), \quad z_{k+1} = z_k - \eta\nabla f(x_k), \quad x_{k+1} = (\nabla\phi)^{-1}(z_{k+1}).} \tag{6}$$

这就是「映射过去，做加法更新，再映射回来」。当 ϕ 满足适当的 Legendre 条件时，还可写 $(\nabla\phi)^{-1} = \nabla\phi^*$，其中

$$\phi^*(z) = \sup_x\{\langle z, x\rangle - \phi(x)\}$$

是凸共轭函数。入门时先掌握式 (**??**) 即可。

两点边界。第一，z_k 的更新一般不是对复合函数 $f((\nabla\phi)^{-1}(z))$ 做普通梯度下降，因为它的梯度还包含链式法则的 Jacobian。第二，有约束时，一阶条件应加入法锥：

$$0 \in \nabla f(x_k) + \frac{1}{\eta}\big[\nabla\phi(x_{k+1}) - \nabla\phi(x_k)\big] + N_X(x_{k+1}),$$

这里假设相关函数在解附近可微并满足所需最优性条件。不能直接丢掉约束使用式 (**??**)。

4 最值得记住的例子：负熵、KL 与乘法更新

在正正交域 $x_i > 0$ 上取

$$\phi(x) = \sum_{i=1}^{n} x_i \log x_i. \tag{7}$$

此时 $(\nabla\phi(x))_i = 1 + \log x_i$，代入定义得到

$$D_\phi(x, y) = \sum_i \left[x_i \log\frac{x_i}{y_i} - x_i + y_i\right]. \tag{8}$$

这是广义 KL 散度。若 $\sum_i x_i = \sum_i y_i = 1$，后两项抵消，成为概率分布上的

$$D_\phi(x, y) = \mathrm{KL}(x\|y) = \sum_i x_i \log\frac{x_i}{y_i}.$$

取 $x_i = 0$ 时可按 $0\log 0 = 0$ 连续延拓，但作为展开中心的 y 仍取严格正向量。

4.1 只有正性约束时：指数乘法更新

由式 (**??**)，逐坐标有

$$1 + \log x_{k+1,i} = 1 + \log x_{k,i} - \eta[\nabla f(x_k)]_i,$$

所以

$$\boxed{x_{k+1,i} = x_{k,i}\exp\big(-\eta[\nabla f(x_k)]_i\big).} \tag{9}$$

加法更新出现在 $\log x$ 坐标中，映回原变量便成为乘法更新。严格正的初值在精确算术下保持严格正。

4.2 概率单纯形上：加上归一化

若 $X = \Delta_n = \{x \ge 0 : \sum_i x_i = 1\}$，取 $x_k > 0$。将约束 $\sum_i x_i = 1$ 的乘子记为 ν，子问题的一阶条件为

$$[\nabla f(x_k)]_i + \frac{1}{\eta}\log\frac{x_{k+1,i}}{x_{k,i}} + \nu = 0.$$

即 $x_{k+1,i} = x_{k,i}\exp(-\eta[\nabla f(x_k)]_i)\exp(-\eta\nu)$。用总和为一确定公共因子：

$$\boxed{x_{k+1,i} = \frac{x_{k,i}\exp(-\eta[\nabla f(x_k)]_i)}{\sum_j x_{k,j}\exp(-\eta[\nabla f(x_k)]_j)}.} \tag{10}$$

这就是单纯形上的 exponentiated gradient 更新。例：$f(x) = x_2$，$x_k = (1/2, 1/2)$，$\eta = \log 2$，未归一化的新权重为 $(1/2, 1/4)$，故 $x_{k+1} = (2/3, 1/3)$。第二个坐标代价更高，其权重便下降。

5 整理原稿中的近端梯度，并与 Mirror Descent 对齐

5.1 近端映射和完成平方

沿用原稿的定义，对适当的闭凸函数 h，

$$\operatorname{prox}_h(x) = \arg\min_{u\in\operatorname{dom} h}\left\{h(u) + \frac{1}{2}\|u - x\|_2^2\right\}.$$

考虑 $\min_x \psi(x) = f(x) + h(x)$，$f$ 光滑，h 允许非光滑。近端梯度为

$$\begin{aligned} x_{k+1} &= \operatorname{prox}_{t_k h}\big(x_k - t_k\nabla f(x_k)\big) \\ &= \arg\min_u\left\{t_k h(u) + \frac{1}{2}\|u - (x_k - t_k\nabla f(x_k))\|_2^2\right\} \\ &= \arg\min_u\left\{h(u) + \frac{1}{2t_k}\|u - (x_k - t_k\nabla f(x_k))\|_2^2\right\}. \end{aligned} \tag{11}$$

令 $d = u - x_k$，展开平方项：

$$\frac{1}{2t_k}\|d + t_k\nabla f(x_k)\|^2 = \frac{1}{2t_k}\|d\|^2 + \langle\nabla f(x_k), d\rangle + \frac{t_k}{2}\|\nabla f(x_k)\|^2.$$

最后一项与 u 无关。删除常数，再加上也与 u 无关的 $f(x_k)$，得

$$x_{k+1} = \arg\min_u\left\{h(u) + f(x_k) + \langle\nabla f(x_k), u - x_k\rangle + \frac{1}{2t_k}\|u - x_k\|^2\right\}. \tag{12}$$

这里是**极小点相同**，并非展开前后的目标函数数值完全相等。$h \equiv 0$ 时退化为梯度下降；$h = \iota_X$（集合的指示函数）时退化为投影梯度下降。

5.2 两者合起来：复合 Mirror Descent

将式 (**??**) 中的平方距离换成 Bregman 散度：

$$\boxed{x_{k+1} = \arg\min_x\left\{\langle\nabla f(x_k), x - x_k\rangle + h(x) + \frac{1}{t_k}D_\phi(x, x_k)\right\}.} \tag{13}$$

这就是常称的 composite mirror descent / Bregman proximal gradient 形式：线性化 f，保留 h，用 D_ϕ 控制一步的变化。

方法	目标函数如何处理	控制步长的项
梯度下降	线性化 f	$\|x - x_k\|^2/(2\eta)$
Mirror Descent	线性化 f	$D_\phi(x, x_k)/\eta$
近端梯度	线性化 f，保留 h	$\|x - x_k\|^2/(2t_k)$
复合 Mirror Descent	线性化 f，保留 h	$D_\phi(x, x_k)/t_k$

特别要区分 Bregman proximal point：$x_{k+1} = \arg\min_x\{f(x) + D_\phi(x, x_k)/\eta\}$。它完整保留 $f(x)$；普通 Mirror Descent 则只保留 f 在当前点的一阶模型。

6 与你前面学的流方法接起来：只补一条线

在无活跃约束、ϕ 二阶可微且 $\nabla^2\phi \succ 0$ 的区域，式 (??) 可以写成

$$\frac{\nabla\phi(x_{k+1}) - \nabla\phi(x_k)}{\eta} = -\nabla f(x_k).$$

当步长趋于零，其连续对应是

$$\frac{\mathrm{d}}{\mathrm{d}t}\nabla\phi(x(t)) = -\nabla f(x(t)) \quad \Longleftrightarrow \quad \nabla^2\phi(x(t))\dot{x}(t) = -\nabla f(x(t)). \tag{14}$$

所以镜像函数通过自己的 Hessian 提供一个随位置变化的度量。再对离散式局部展开，令 $s_k = x_{k+1} - x_k$，有

$$\nabla\phi(x_k + s_k) - \nabla\phi(x_k) = \nabla^2\phi(x_k)s_k + o(\|s_k\|),$$

从而在小步长下

$$s_k \approx -\eta[\nabla^2\phi(x_k)]^{-1}\nabla f(x_k).$$

这只是 Mirror Descent 的*局部近似*，一般不等于其精确有限步更新。$\phi(x) = \|x\|^2/2$ 对应普通梯度流；形式上取 $\phi = f$ 且 Hessian 正定时，连续流成为 Newton 流，但离散更新条件是

$$\nabla f(x_{k+1}) = (1 - \eta)\nabla f(x_k),$$

仍需反求 x_{k+1}，不能直接当作普通 Newton 步。这正好对应之前笔记的「残差空间离散」。

与 Sinkhorn 的一个定位。 熵正则 OT 可以写成带边缘约束的广义 KL 投影问题；Sinkhorn 利用行、列边缘集合上的交替 KL 投影。它与负熵 Mirror Descent 共享 Bregman 几何，但「都用 KL」并不意味着两者就是同一更新式。入门先记住这种几何联系即可。

先掌握到哪里。 能从式 (??) 推出镜像坐标式 (??)，能分别代入平方范数和负熵，并能区分 Mirror Descent、近端梯度与 Bregman proximal point，就抓住了这一轮入门的核心。步长选择、收敛速率和加速方法留待之后；它们还需要目标函数与镜像几何之间的光滑性、凸性等假设。