Sinkhorn 算法理解

对偶坐标上升及 Newton 块中的 Gauss–Seidel

Basiliscus

2026 年 9 月 22 日

符号与记法

符号	含义
$P,\ M$	传输矩阵与代价矩阵
$a,\ b$	源边缘与目标边缘质量向量
$\lambda,\ \mu$	两组边缘约束对应的拉格朗日乘子
$\varepsilon > 0$	熵正则化参数
$K = \exp(-M/\varepsilon)$	Gibbs 核矩阵
$u = \mathrm{e}^{-\lambda/\varepsilon},\ v = \mathrm{e}^{-\mu/\varepsilon}$	Sinkhorn 缩放向量
$\mathbf{1},\ I$	维数由上下文确定的全一向量与单位矩阵
$\odot,\ \oslash$	逐元素乘法与除法
$\exp(\cdot),\ \log(\cdot)$	对向量或矩阵逐元素作用的指数与对数
$\langle \cdot, \cdot \rangle$	向量的欧氏内积或矩阵的 Frobenius 内积
$\mathrm{diag}(x),\ (\cdot)^{\mathsf{T}}$	以 x 为对角元的对角矩阵与转置运算

1 LM 流

对一般目标函数 f，LM 流写作

$$\big(\nabla^2 f(x(t)) + h(t) I\big)\dot{x}(t) = -\nabla f(x(t)). \tag{1}$$

当 $h(t)$ 较大时，二阶项相对较弱，有

$$\dot{x}(t) \approx -\frac{1}{h(t)} \nabla f(x(t)),$$

即退化为带时间缩放的梯度流；当 $h(t)$ 较小时，则更接近连续 Newton 流。

2　熵正则最优传输及其对偶

考虑问题

$$\begin{aligned} \min_{P>0} \quad & \langle P, M\rangle + \varepsilon\langle P, \log P - \mathbf{1}\mathbf{1}^{\mathsf{T}}\rangle, \\ \text{s.t.} \quad & P\mathbf{1} = a, \\ & P^{\mathsf{T}}\mathbf{1} = b. \end{aligned} \tag{2}$$

这里 $P>0$ 表示 $P_{ij}>0$。对应的拉格朗日函数为

$$L(P,\lambda,\mu) = \langle P, M\rangle + \varepsilon\langle P, \log P - \mathbf{1}\mathbf{1}^{\mathsf{T}}\rangle + \langle \lambda, P\mathbf{1} - a\rangle + \langle \mu, P^{\mathsf{T}}\mathbf{1} - b\rangle. \tag{3}$$

由 $\nabla_P L = 0$，逐项得到

$$M_{ij} + \varepsilon \log P_{ij} + \lambda_i + \mu_j = 0.$$

令

$$K = \exp\left(-\frac{M}{\varepsilon}\right), \tag{4}$$

则

$$P = \operatorname{diag}\left(\mathrm{e}^{-\lambda/\varepsilon}\right) K \operatorname{diag}\left(\mathrm{e}^{-\mu/\varepsilon}\right). \tag{5}$$

对偶函数为

$$g(\lambda,\mu) := \inf_{P>0} L(P,\lambda,\mu) = -\varepsilon\left\langle \mathrm{e}^{-\lambda/\varepsilon}, K\mathrm{e}^{-\mu/\varepsilon}\right\rangle - \langle a,\lambda\rangle - \langle b,\mu\rangle. \tag{6}$$

于是

$$\nabla g(\lambda,\mu) = \begin{pmatrix} P\mathbf{1} - a \\ P^{\mathsf{T}}\mathbf{1} - b \end{pmatrix}, \tag{7}$$

且

$$\nabla^2 g(\lambda,\mu) = -\frac{1}{\varepsilon}\begin{pmatrix} \operatorname{diag}(P\mathbf{1}) & P \\ P^{\mathsf{T}} & \operatorname{diag}(P^{\mathsf{T}}\mathbf{1}) \end{pmatrix}. \tag{8}$$

记

$$A(P) := \begin{pmatrix} \operatorname{diag}(P\mathbf{1}) & P \\ P^{\mathsf{T}} & \operatorname{diag}(P^{\mathsf{T}}\mathbf{1}) \end{pmatrix}. \tag{9}$$

因为 g 是凹函数，对 $-g$ 应用 LM 流可得

$$\left(\frac{1}{\varepsilon}A(P) + h(t)I\right)\begin{pmatrix} \dot\lambda \\ \dot\mu \end{pmatrix} = \begin{pmatrix} P\mathbf{1} - a \\ P^{\mathsf{T}}\mathbf{1} - b \end{pmatrix}. \tag{10}$$

核对说明

由于变换 $\lambda \mapsto \lambda + c\mathbf{1}$、$\mu \mapsto \mu - c\mathbf{1}$ 不改变 P，对偶势具有规范不唯一性，因此 $A(P)$ 通常是半正定且奇异的。加入 $h(t)I$（$h(t)>0$）同时起到 LM 正则化作用。

3 Sinkhorn 的第一种理解：对偶坐标上升

Sinkhorn 迭代可以写成对偶问题的交替坐标最大化：

$$\begin{aligned}\lambda^{k+1} &= \arg\max_{\lambda} g(\lambda, \mu^k),\\ \mu^{k+1} &= \arg\max_{\mu} g(\lambda^{k+1}, \mu).\end{aligned} \tag{11}$$

第一个一阶最优条件为

$$\operatorname{diag}\left(\mathrm{e}^{-\lambda^{k+1}/\varepsilon}\right) K \operatorname{diag}\left(\mathrm{e}^{-\mu^k/\varepsilon}\right) \mathbf{1} - a = 0, \tag{12}$$

第二个一阶最优条件为

$$\operatorname{diag}\left(\mathrm{e}^{-\mu^{k+1}/\varepsilon}\right) K^{\mathsf{T}} \operatorname{diag}\left(\mathrm{e}^{-\lambda^{k+1}/\varepsilon}\right) \mathbf{1} - b = 0. \tag{13}$$

因此

$$\begin{aligned}\mathrm{e}^{-\lambda^{k+1}/\varepsilon} &= a \oslash \left(K \operatorname{diag}\left(\mathrm{e}^{-\mu^k/\varepsilon}\right) \mathbf{1}\right),\\ \mathrm{e}^{-\mu^{k+1}/\varepsilon} &= b \oslash \left(K^{\mathsf{T}} \operatorname{diag}\left(\mathrm{e}^{-\lambda^{k+1}/\varepsilon}\right) \mathbf{1}\right).\end{aligned} \tag{14}$$

等价地，

$$\begin{aligned}\lambda^{k+1} &= \varepsilon \log\left[\left(K \operatorname{diag}\left(\mathrm{e}^{-\mu^k/\varepsilon}\right) \mathbf{1}\right) \oslash a\right],\\ \mu^{k+1} &= \varepsilon \log\left[\left(K^{\mathsf{T}} \operatorname{diag}\left(\mathrm{e}^{-\lambda^{k+1}/\varepsilon}\right) \mathbf{1}\right) \oslash b\right].\end{aligned} \tag{15}$$

普通的对偶梯度上升应写成

$$\lambda^{k+1} = \lambda^k + \tau\big(P^k\mathbf{1} - a\big), \tag{16}$$

将 Sinkhorn 关于 λ^{k+1} 的更新显性地写为关于 λ^k 的函数，得到

$$\begin{aligned}\mathrm{e}^{-\lambda^{k+1}/\varepsilon} &= \mathrm{e}^{-\lambda^k/\varepsilon} \odot \left[a \oslash \left(\operatorname{diag}\left(\mathrm{e}^{-\lambda^k/\varepsilon}\right) K \operatorname{diag}\left(\mathrm{e}^{-\mu^k/\varepsilon}\right) \mathbf{1}\right)\right]\\ &= \mathrm{e}^{-\lambda^k/\varepsilon} \odot \left[a \oslash (P^k\mathbf{1})\right],\\ \lambda^{k+1} &= \lambda^k - \varepsilon \log\left[a \oslash (P^k\mathbf{1})\right]\\ &= \lambda^k + \varepsilon \log\left[(P^k\mathbf{1}) \oslash a\right].\end{aligned} \tag{17}$$

因此，Sinkhorn 使用的是对数边缘残差，而不是式 (16) 中的加性边缘残差。

核对说明

原笔记中“普通梯度下降”一行若针对凹对偶函数 g，应改为梯度上升，即式 (16) 的正号；若改为最小化 $-g$，结论仍然相同。

4 Sinkhorn 的第二种理解：Newton 型方程上的忽略副对角线的 Gauss–Seidel

由式 (7)–(8)，对偶最大化的 Newton 方程为

$$\begin{pmatrix} \operatorname{diag}(P^k\mathbf{1}) & P^k \\ (P^k)^{\mathsf{T}} & \operatorname{diag}((P^k)^{\mathsf{T}}\mathbf{1}) \end{pmatrix} \begin{pmatrix} \Delta\lambda^k \\ \Delta\mu^k \end{pmatrix} = \varepsilon \begin{pmatrix} P^k\mathbf{1} - a \\ (P^k)^{\mathsf{T}}\mathbf{1} - b \end{pmatrix}. \tag{18}$$

令

$$u = \mathrm{e}^{-\lambda/\varepsilon}, \qquad v = \mathrm{e}^{-\mu/\varepsilon}, \tag{19}$$

则

$$P = \operatorname{diag}(u) K \operatorname{diag}(v), \tag{20}$$

并且

$$\begin{aligned} P\mathbf{1} &= \operatorname{diag}(u) K v, \\ P^{\mathsf{T}}\mathbf{1} &= \operatorname{diag}(v) K^{\mathsf{T}} u. \end{aligned} \tag{21}$$

定义（跟 u, v 相关的）边缘残差：

$$F(u, v) = \begin{pmatrix} \operatorname{diag}(u) K v - a \\ \operatorname{diag}(v) K^{\mathsf{T}} u - b \end{pmatrix}. \tag{22}$$

其 Jacobian 为

$$J_F(u, v) = \begin{pmatrix} \operatorname{diag}(Kv) & \operatorname{diag}(u) K \\ \operatorname{diag}(v) K^{\mathsf{T}} & \operatorname{diag}(K^{\mathsf{T}} u) \end{pmatrix}. \tag{23}$$

因此 Newton 方程可以写成

$$-\begin{pmatrix} \operatorname{diag}(Kv^k) & \operatorname{diag}(u^k) K \\ \operatorname{diag}(v^k) K^{\mathsf{T}} & \operatorname{diag}(K^{\mathsf{T}} u^k) \end{pmatrix} \begin{pmatrix} \Delta u^k \\ \Delta v^k \end{pmatrix} = \begin{pmatrix} \operatorname{diag}(u^k) K v^k - a \\ \operatorname{diag}(v^k) K^{\mathsf{T}} u^k - b \end{pmatrix}. \tag{24}$$

在式 (24) 上忽略副对角线 Gauss–Seidel：先固定 v^k，忽略第一行第二项，得到

$$-\operatorname{diag}(Kv^k) \Delta u^k = \operatorname{diag}(u^k) K v^k - a. \tag{25}$$

利用 $\Delta u^k = u^{k+1} - u^k$，有

$$\begin{aligned} -\operatorname{diag}(Kv^k)(u^{k+1} - u^k) &= \operatorname{diag}(u^k) K v^k - a, \\ u^{k+1} - u^k &= \left(a - \operatorname{diag}(u^k) K v^k\right) \oslash (Kv^k), \\ u^{k+1} &= a \oslash (Kv^k). \end{aligned} \tag{26}$$

随后在 (u^{k+1}, v^k) 处重新计算第二个对角块，并固定刚更新的 u^{k+1}，同理得到

$$v^{k+1} = b \oslash (K^{\mathsf{T}} u^{k+1}). \tag{27}$$

这正是 Sinkhorn 迭代：

$$\boxed{\begin{aligned} u^{k+1} &= a \oslash (Kv^k), \\ v^{k+1} &= b \oslash (K^{\mathsf{T}} u^{k+1}). \end{aligned}} \tag{28}$$

5 在 λ, μ 变量中与 Sinkhorn 的关系

若直接在式 (18) 中忽略耦合块，则 λ 子步满足

$$\operatorname{diag}(P^k\mathbf{1})\Delta\lambda^k = \varepsilon(P^k\mathbf{1} - a), \tag{29}$$

从而

$$\Delta\lambda^k = \varepsilon\left[\mathbf{1} - a \oslash (P^k\mathbf{1})\right]. \tag{30}$$

而 Sinkhorn 的精确增量是

$$\Delta\lambda^k_{\text{Sinkhorn}} = -\varepsilon\log\left[a \oslash (P^k\mathbf{1})\right] = \varepsilon\log\left[(P^k\mathbf{1}) \oslash a\right]. \tag{31}$$

当 $P^k\mathbf{1}$ 接近 a 时，令 $x = (P^k\mathbf{1}) \oslash a$，则逐分量有

$$\log x = 1 - x^{-1} + \mathcal{O}\big((x-1)^2\big).$$

故式 (30) 与式 (31) 在最优解附近一阶等价，但一般并不严格相同。

核对说明

严格地说，在 u, v 缩放变量下作上述非线性块 Gauss–Seidel （每个子步后重新计算下一对角块），可以精确恢复 Sinkhorn。若把整个 Jacobian 冻结在 (u^k, v^k)，只对同一个线性 Newton 方程作一次普通块 Gauss–Seidel，第二个子步一般不会严格等于 Sinkhorn。若直接在 λ, μ 对偶变量下忽略耦合块，得到的只是 Sinkhorn 对数更新在最优解附近的一阶近似。

核对结论

1. 熵正则 OT 的拉格朗日函数、最优 P、对偶梯度与 Hessian 的主线正确。
2. 普通对偶迭代应为梯度上升，符号见式 (16)。
3. 若 $\Delta\lambda^k, \Delta\mu^k$ 表示真实对偶增量，Newton 方程右端应含 ε，见式 (18)；只有把增量预先除以 ε 时才能省略该因子。
4. Sinkhorn 作为对偶坐标上升是精确解释；在 u, v 变量下作逐块重算的非线性 Gauss–Seidel 也可精确恢复 Sinkhorn。
5. 在 λ, μ 变量下直接忽略 Newton 耦合块，只与 Sinkhorn 局部一阶等价。